

Rezultati Eksperimenta

(Drugi domaći zadatak - Vještačka Inteligencija)


Marko Mešter 15/21


Kroz ovaj rad testirao sam koja kombinacija modela i vektorizacije je najbolja za detekciju AI-generisanog teksta. Od modela koristio sam: Logistička Regresija, Naivni Bajesov klasifikator, Stablo Odlučivanja, Random Forest klasifikator i Extra Trees klasifikator. Od načina vektorizacije koristio sam Count Vektorizaciju i TF-IDF vektorizaciju. Svaka kombinacija modela i vektorizacije se testirala sa lematizacijom i bez lematizacije. Kod koji sam napisao se izvršava xx minuta zbog prolaženja kroz sve kombinacije i zbog veličine dataseta.

```
Logistička regresija sa Count vektorizacijom bez lematizacije: 0.9925
Logistička regresija sa Count vektorizacijom sa lematizacijom: 0.9921
Logistička regresija sa TF-IDF vektorizacijom bez lematizacije: 0.9877
Logistička regresija sa TF-IDF vektorizacijom sa lematizacijom: 0.9877
Naivni bajesov klasifikator sa Count vektorizacijom bez lematizacije: 0.9684
Naivni bajesov klasifikator sa Count vektorizacijom sa lematizacijom: 0.9668
Naivni bajesov klasifikator sa TF-IDF vektorizacijom bez lematizacije: 0.9638
Naivni bajesov klasifikator sa TF-IDF vektorizacijom sa lematizacijom: 0.9621
Stablo odlucivanja sa Count vektorizacijom bez lematizacije: 0.9227
stablo odlucivanja sa Count vektorizacijom sa lematizacijom: 0.9220
Stablo odlucivanja sa TF-IDF vektorizacijom bez lematizacije: 0.9238
Stablo odlucivanja sa TF-IDF vektorizacijom sa lematizacijom: 0.9214
Random Forest sa Count vektorizacijom bez lematizacije: 0.6186
Random forest sa Count vektorizacijom sa lematizacijom: 0.6182
Random forest sa TF-IDF vektorizacijom bez lematizacije: 0.6180
Random forest sa TF-IDF vektorizacijom sa lematizacijom: 0.6179
Extra trees sa Count vektorizacijom bez lematizacije: 0.6563
Extra trees sa Count vektorizacijom sa lematizacijom: 0.6595
Extra trees sa TF-IDF vektorizacijom bez lematizacije: 0.6596
Extra trees sa TF-IDF vektorizacijom sa lematizacijom: 0.6694
```

U prvom testiranju najveću tačnost dostiže Logistička Regresija sa Count vektorizacijom bez lematizacije. Postignuta je tačnost od 0.9925, dok je tačnost istog sa lematizacijom bila 0.9921. U ovom slučaju lematizacija daje gori rezultat. Takođe, Logistička Regresija sa Count vektorizacijom je jedina kombinacija modela i vektorizacije koja je dostigla tačnost veću od 99%. Iako se TF-IDF vektorizacija smatra boljom vektorizacijom za klasifikovanje teksta (barem kako internet kaže) u mom eksperimentu se to nije pokazalo tako. Jedino je Random Forest bez lematizacije dao bolji rezultat sa TF-IDF vektorizacijom nego sa Count vektorizacijom, svi ostali modeli su dali bolje rezultate sa Count vektorizacijom.

Takođe Logistička Regresija sa Count vektorizacijom bez lematizacije je postigla tačnost veću od 99% sa trening veličinom od 55%, što znači da je dovoljno samo 50% treninga za ovaj model da daje ovakvu tačnost!






+L označava korišćenje lematizacije / -L označava nekorisćenje lematizacije

Sledeća dva slova su ili TF (TF-IDF vektorizacija) ili Cv(Count vektorizacija)

Poslednja dva slova su oznaka modela: LR (Logistic Regression), NV (Naive Bayes), DT (Decision Tree), RF (Random Forest) i ET (Extra Trees).



Testiranje uticaja broja razlicitih tema na tacnost je pokazalo svaki put razlicite rezultate ali je svaki put tacnost bila vecinski u rastucem trendu. Takođe ovo sam testirao samo sa najboljim modelom (Logistička Regresija sa Count vektorizacijom bez lematizacije), i u mojih par pokretanja koda nikad nije dostignuta tacnost od 99%, što govori da je testiranje modela na što raznolikijim tekstom daje bolje rezultate.