

Vještačka inteligencija - drugi domaći zadatak: Detekcija AI-generisanog teksta

Sve veća prisutnost AI alata u svakodnevnom životu, pored povećanja produktivnosti i drugih benefita, ima i loše strane. Na primjer, zloupotreba ChatGPT-a i sličnih velikih jezičkih modela dovodi do problema u akademskom svijetu, kao što je plagiranje naučnih radova, prepisivanje domaćih zadataka i slično. U tu svrhu razvijaju se sistemi za detekciju tekstova koje je generisao neki AI model. Vaš zadatak je da proučite ovaj problem (neke dodatne informacije možete naći u okviru [DAIGT Kaggle izazova](#)) i pokušate da ga riješite upotrebom metoda za obradu prirodnog jezika. Preciznije, potrebno je riješiti problem binarne klasifikacije: da li je dati tekst napisao čovjek (klasa 0) ili neki veliki jezički model (klasa 1).

U programskom jeziku Python, uz upotrebu biblioteka kao što su scikit-learn, numpy, pandas i slične, implementirati rješenje ovoga problema. Isprobati različite tehnike za preprocesiranje teksta i njegovo predstavljanje u numeričkom obliku (kao što su lematizacija, count vektorizacija, TF-IDF vektorizacija i sl.), kao i različite modele mašinskog učenja koji bi riješili binarni klasifikacioni problem (logistička regresija, naivni Bajesov klasifikator, stablo odlučivanja, ansambl metodi itd.). Preporučujemo da za razvoj modela koristite [DAIGT V2 dataset](#). Razmotriti sljedeće mogućnosti za podjelu dataseta, i implementirati odgovarajuće eksperimente za svaku od njih:

- Obična nasumična podjela na trening i test set u nekoj razmjeri (npr. 80:20). Koliki je minimalni procenat dataseta potrebno uzeti za trening, da bi model na preostalim, testnim podacima postigao preciznost (accuracy) od 99%?
- Obučavanje modela samo na određenim temama tekstova (evidentiranim unutar kolone `prompt_name`), a zatim testiranje na preostalim temama, koje model nije "vidio" tokom treninga. Ispitati kako veličina seta tema odabranih za trening utiče na performanse modela na svim ostalim temama.

Rezultate eksperimenata vizuelizovati u vidu tabela i/ili grafika, i objasniti ih u seminarskom radu. Diskutovati kako krajnje performanse klasifikacije zavise od načina preprocesiranja teksta i odabranog klasifikacionog modela.

Implementirani programski kod i seminarski rad postaviti na Google Drive (ili neku sličnu cloud storage platformu) i link do rada poslati na adresu nikola.p@ucg.ac.me najkasnije do prvog termina završnog ispita (3.2.2025).